Language Identification Natural Language Processing Project

Team Members: DARSH KUMAR - E20BCA007 SAUBHAGAYA SHARMA - E20BCA003 ANIKET SINGH - E20BCA026

Import required libraries

```
In [1]: import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
```

Load data

```
In [2]: data = pd.read csv('dataset.csv')
In [3]: data.head()
Out[3]:
                                                                Text language
           0
                          klement gottwaldi surnukeha palsameeriti ning ...
                                                                       Estonian
                           sebes joseph pereira thomas på eng the jesuit...
                                                                       Swedish
           2
                                                                           Thai
                          ถนนเจริญกรุง อักษรโรมัน thanon charoen krung เ...
           3 விசாகப்பட்டினம் தமிழ்ச்சங்கத்தை இந்துப் பத்திர...
                                                                          Tami
                           de spons behoort tot het geslacht haliclona en...
                                                                          Dutch
In [4]: data.shape
Out[4]: (22000, 2)
```

Check Counts of Language

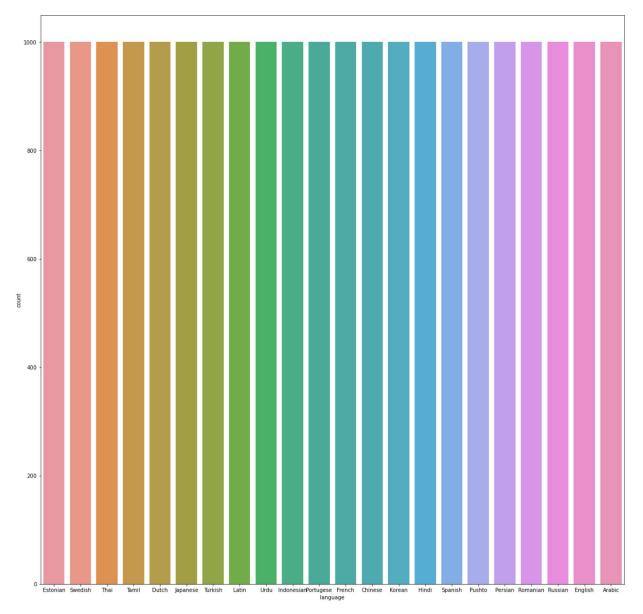
```
In [5]: data['language'].value_counts()
Out[5]: Estonian
                       1000
        Swedish
                       1000
        English
                       1000
        Russian
                       1000
        Romanian
                       1000
        Persian
                       1000
        Pushto
                       1000
        Spanish
                       1000
        Hindi
                       1000
        Korean
                       1000
        Chinese
                       1000
        French
                       1000
        Portugese
                       1000
        Indonesian
                       1000
        Urdu
                       1000
        Latin
                       1000
        Turkish
                       1000
        Japanese
                       1000
        Dutch
                       1000
        Tamil
                       1000
        Thai
                       1000
        Arabic
                       1000
        Name: language, dtype: int64
In [6]: data['language'][2]
Out[6]: 'Thai'
```

Visualize that how much language and how much sentences in dataset

```
In [7]: plt.figure(figsize=(20,20))
sns.countplot(data['language'])
```

C:\Users\DARSH KUMAR\anaconda3\lib\site-packages\seaborn_decorators.py:36: Fut
ureWarning: Pass the following variable as a keyword arg: x. From version 0.12,
the only valid positional argument will be `data`, and passing other arguments
without an explicit keyword will result in an error or misinterpretation.
 warnings.warn(

Out[7]: <AxesSubplot:xlabel='language', ylabel='count'>



```
In [8]: data['Text'][3]
```

Out[8]: 'விசாகப்பட்டினம் தமிழ்ச்சங்கத்தை இந்துப் பத்திரிகை-விசாகப்பட்டின ஆ சிரியர் சம்பத்துடன் இணைந்து விரிவுபடுத்தினார் ஆண்டுகள் தொடர்ந்து செ யலராக இருந்து தமிழ்மன்றத்தை நடத்திச் சென்றார் கோவை செம்மொழி மாநாட்டில் "தமிழ்ச்சங்கங்களும் தமிழும்" எனும் தலைப்பில் பிற மாநிலங்க ளில் தமிழ்வளர்ச்சி பற்றி கட்டுரை வாசித்தார்'

Remove stopwards from sentences

```
In [9]: import nltk
from nltk.corpus import stopwords
from nltk.stem import PorterStemmer
import re
```

Convert sentences into vector

LabelEncoding (Convert language name into

1,2,3....etc)

Final data Looks like

```
In [17]: data1 = pd.DataFrame(np.c_[corpus,y],columns=['Sentence','Language'])
In [18]: data1
Out[18]:
```

	Sentence	Language
0	lement gottwaldi surnukeha palsameer ning paig	4
1	ebe joseph pereira thoma på eng the jesuit and	17
2	ถนนเจริญกรุง อักษรโรมัน thanon charoen krung เ	19
3	விசாகப்பட்டினம் தமிழ்ச்சங்கத்தை இந்துப் பத்திர	18
4	e spon behoort tot het geslacht haliclona en b	2
21995	or du terrain le anné et sont de anné de crise	5
21996	ใน พศ หลักจากที่เสด็จประพาสแหลมมลายู ชวา อินเด	19
21997	on motivo de la celebración del septuagésimoqu	16
21998	年月,當時還只有歲的她在美國出道,以mai-k名義推出首張英文《babi i like》,由	1
21999	aprili sonda spațială messeng a nasa și-a înch	14

22000 rows × 2 columns

split data into training and testing

```
In [19]: from sklearn.model_selection import train_test_split
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2, random
In [20]: X_train.shape, X_test.shape, y_train.shape, y_test.shape
Out[20]: ((17600, 10000), (4400, 10000), (17600,), (4400,))
```

Define model

```
In [21]: from sklearn.naive_bayes import MultinomialNB
In [22]: classifier = MultinomialNB().fit(X_train,y_train)
```

Test model on test data

```
In [23]: pred = classifier.predict(X_test)
In [24]: pred
Out[24]: array([10, 14, 20, ..., 19, 21, 17])
In [25]: y_test
Out[25]: array([10, 14, 20, ..., 19, 21, 17])
```

Evaluate

```
Language_detector_NLP - Jupyter Notebook
            from sklearn.metrics import accuracy_score,confusion_matrix
In [26]:
            print(accuracy_score(y_test,pred))
            print(confusion_matrix(y_test,pred))
            0.923409090909091
            [[193
                            0
                                 0
                                                 0
                                                           0
                                                                 0
                                                                      0
                                                                           0
                                                                                0
                                                                                           0
                                                                                                0
                                                                                                     0
                                                                                                          0
                      0
                                      0
                                           0
                                                      0
                                                                                      0
                      0
                            0
                                 0]
                 0
                                17 112
                                                                                                     2
             62
                            0
                                           3
                                                 0
                                                      0
                                                           0
                                                                 0
                                                                      0
                                                                           0
                                                                                0
                                                                                      0
                                                                                           0
                                                                                                0
                                                                                                          0
                 0
                      0
                            1
                                 0]
                                 3
                 0
                      0
                         202
                                           2
                                                                 0
                                                                           0
                                                                                                0
                                                                                                          0
                                      0
                                                 0
                                                      0
                                                           0
                                                                      1
                                                                                0
                                                                                      0
                                                                                           0
                                                                                                     0
                 0
                      0
                            0
                                 0]
                            0 199
                 0
                      1
                                      0
                                           0
                                                 0
                                                      0
                                                           0
                                                                0
                                                                      0
                                                                           0
                                                                                0
                                                                                      0
                                                                                           0
                                                                                                0
                                                                                                     0
                                                                                                          0
                 0
                      0
                            0
                                 0]
                 0
                      0
                            0
                                 2 171
                                           1
                                                 0
                                                      0
                                                           0
                                                                 0
                                                                      0
                                                                           0
                                                                                0
                                                                                      0
                                                                                           0
                                                                                                1
                                                                                                     0
                                                                                                          0
              [
                 0
                      0
                            1
                                 0]
                                      0 195
                 0
                      0
                            0
                                 1
                                                 0
                                                      0
                                                           0
                                                                 0
                                                                      0
                                                                           0
                                                                                0
                                                                                      0
                                                                                           0
                                                                                                0
                                                                                                     0
                                                                                                          0
                 0
                      0
                            0
                                 0]
                 0
                            0
                                 4
                                           0 188
                                                                           0
                                                                                                          0
                      0
                                      0
                                                      0
                                                           0
                                                                 0
                                                                      0
                                                                                0
                                                                                      0
                                                                                           0
                                                                                                0
                                                                                                     0
                 0
                      0
                            0
                                 0]
                 0
                      0
                            0
                                 1
                                           0
                                                 0 191
                                                           0
                                                                 0
                                                                      0
                                                                           0
                                                                                0
                                                                                      0
                                                                                           0
                                                                                                0
                                                                                                     0
                                                                                                          0
                 0
                      0
                            0
                                 0]
                                 8
                                                          65
                 0
                     12
                            0
                                                      0
                                                                 0
                                                                           0
                                                                                                     3
                                                                                                          1
                                     88
                                           3
                                                 0
                                                                      0
                                                                                0
                                                                                      0
                                                                                           1
                                                                                                1
                 0
                      0
                            0
                                 0]
                 0
                      0
                            0
                                 0
                                      4
                                           0
                                                 0
                                                      0
                                                           0
                                                              200
                                                                      0
                                                                           0
                                                                                0
                                                                                      0
                                                                                           0
                                                                                                0
                                                                                                     0
                                                                                                          0
                 0
                      0
                            0
                                 0]
                 0
                      0
                            0
                                11
                                      0
                                           1
                                                 0
                                                      0
                                                           0
                                                                 0 186
                                                                           0
                                                                                0
                                                                                      0
                                                                                           2
                                                                                                0
                                                                                                     2
                                                                                                          0
                 0
                      0
                            0
                                 0]
                 0
                       0
                            0
                                 0
                                      0
                                           0
                                                 0
                                                      0
                                                           0
                                                                 0
                                                                      0
                                                                        186
                                                                                0
                                                                                      0
                                                                                           0
                                                                                                0
                                                                                                     0
                                                                                                          0
                 0
                                 0]
                      0
                            0
                                15
                                                                           0 179
                 0
                      0
                            1
                                      1
                                           0
                                                 0
                                                      0
                                                           0
                                                                 0
                                                                      0
                                                                                      0
                                                                                           0
                                                                                                0
                                                                                                     0
                                                                                                          0
                                 0]
                 0
                      0
                            0
                                 7
                 0
                      0
                            0
                                      1
                                           0
                                                 0
                                                      0
                                                           0
                                                                 0
                                                                      0
                                                                           0
                                                                                0
                                                                                   199
                                                                                           0
                                                                                                0
                                                                                                     0
                                                                                                          0
                 0
                       0
                            0
                                 0]
                 0
                                 2
                                                                                                          0
                      0
                            0
                                      0
                                           1
                                                 0
                                                      0
                                                           0
                                                                 0
                                                                      0
                                                                           0
                                                                                0
                                                                                      0
                                                                                        203
                                                                                                0
                                                                                                     0
                 0
                      0
                            0
                                 0]
                 0
                      0
                            0
                                 3
                                      1
                                           0
                                                 0
                                                      0
                                                           0
                                                                0
                                                                      0
                                                                           0
                                                                                0
                                                                                      0
                                                                                           0 211
                                                                                                     0
                                                                                                          0
                 0
                      0
                            0
                                 0]
                 0
                      0
                            0
                                 3
                                           1
                                                 0
                                                      0
                                                           0
                                                                 0
                                                                      0
                                                                           0
                                                                                 1
                                                                                      0
                                                                                           0
                                                                                                0
                                                                                                  185
                                                                                                          0
                 0
                      0
                            0
                                 0]
                 0
                                                                                                        204
                       0
                            0
                                 0
                                           0
                                                 0
                                                      0
                                                           0
                                                                 0
                                                                      0
                                                                           0
                                                                                0
                                                                                      0
                                                                                           0
                                                                                                0
                                                                                                     0
```

Confusion matrix

0]

0]

0]

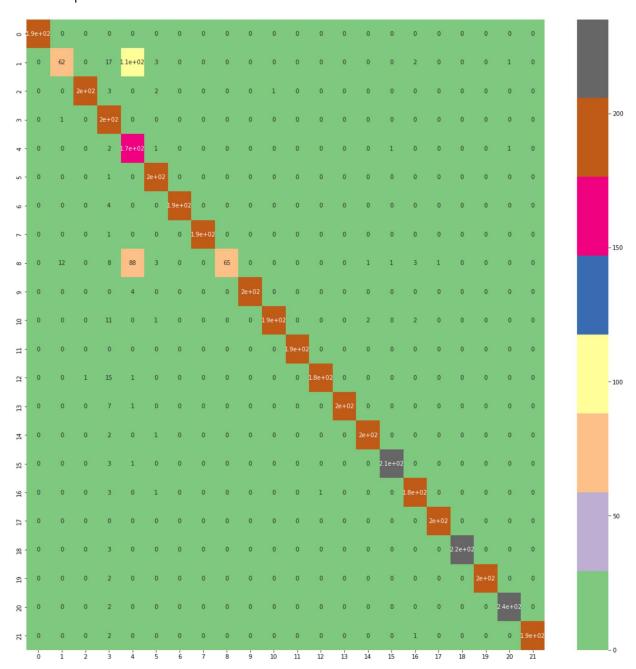
0]

0 187]]

 0 235

In [27]: plt.figure(figsize=(20,20))
sns.heatmap(confusion_matrix(y_test,pred),annot=True,cmap=plt.cm.Accent)

Out[27]: <AxesSubplot:>



Actual Language and Predicted Language

```
In [28]: fnl = pd.DataFrame(np.c_[y_test,pred],columns=['Actual','Predicted'])
fnl
```

Out[28]:

Actual	Predicted
10	10
14	14
20	20
16	16
12	12
20	20
1	4
19	19
21	21
17	17
	10 14 20 16 12 20 1 19 21

4400 rows × 2 columns

Save model

Load model

```
In [30]: model = joblib.load('language_identification.sav')
```

Test model

```
In [31]: def test_model(test_sentence):
             languages = {
              'Arabic' : 0,
              'Chinese' : 1,
              'Dutch' : 2,
              'English': 3,
              'Estonian' : 4,
              'French' : 5,
              'Hindi' : 6,
              'Indonesian' : 7,
              'Japanese' : 8,
              'Korean' : 9,
              'Latin' : 10,
              'Persian' : 11,
              'Portugese': 12,
              'Pushto' : 13,
              'Romanian' : 14,
              'Russian' : 15,
              'Spanish': 16,
              'Swedish' : 17,
              'Tamil' : 18,
              'Thai' : 19,
              'Turkish' : 20,
              'Urdu' : 21
             }
             rev = re.sub('^[a-zA-Z]',' ',test_sentence)
             rev = rev.lower()
             rev = rev.split()
             rev = [ps.stem(word) for word in rev if word not in set(stopwords.words())]
             rev = ' '.join(rev)
             rev = cv.transform([rev]).toarray()
             output = model.predict(rev)[0]
             keys = list(languages)
             values = list(languages.values())
             position = values.index(output)
             output = keys[position]
             print(output)
```

```
In [32]: test_model('நாங்கள் நல்ல சிறுவர்கள்')
```

Tamil

```
In [33]: test_model('พวกเราเป็นเด็กดี')
```

Thai

In [34]: test_model('İyi ki doğdun Raman')

Turkish

In [35]: test_model('in quo habitas')

Latin

In [36]: pd.DataFrame(np.c_[data['Text'],data['language'],y],columns=['Sentence','Language

Out[36]:

	Sentence	Language	Encoded
0	klement gottwaldi surnukeha palsameeriti ning	Estonian	4
1	sebes joseph pereira thomas på eng the jesuit	Swedish	17
2	ถนนเจริญกรุง อักษรโรมัน thanon charoen krung เ	Thai	19
3	விசாகப்பட்டினம் தமிழ்ச்சங்கத்தை இந்துப் பத்திர	Tamil	18
4	de spons behoort tot het geslacht haliclona en	Dutch	2
21995	hors du terrain les années et sont des année	French	5
21996	ใน พศ หลักจากที่เสด็จประพาสแหลมมลายู ชวา อินเ	Thai	19
21997	con motivo de la celebración del septuagésimoq	Spanish	16
21998	年月,當時還只有歲的她在美國出道,以mai-k名義推出首張英文《baby i like》,由	Chinese	1
21999	aprilie sonda spațială messenger a nasa și-a	Romanian	14

22000 rows × 3 columns

```
In [37]: # Languages = {
                'Arabic' : 0,
                'Chinese' : 1,
          #
                'Dutch' : 2,
                'English': 3,
                'Estonian' : 4,
                'French' : 5,
                'Hindi' : 6,
                'Indonesian' : 7,
                'Japanese' : 8,
                'Korean' : 9,
                'Latin' : 10,
                'Persian' : 11,
                'Portugese' : 12,
                'Pushto' : 13,
                'Romanian' : 14,
                'Russian' : 15,
                'Spanish' : 16,
                'Swedish' : 17,
                'Tamil' : 18,
                'Thai' : 19,
                'Turkish' : 20,
                'Urdu' : 21
          # }
```

```
In [38]: # creating a pickle file
import pickle
pickle.dump(classifier, open('language_detector.pkl','wb'))
```